

@ele_course

Spring Semester Project 2026

Project Duration

March 2026 - June 2026

ELECOURSE 2026 Spring Project: Development of an End-to-End ECG/PPG-Based Cuffless Blood Pressure Estimation System

Authors 주민규^{PM}, 최연호^{PM}, 이은설^{TL}, 정성현^{TL}, 김시우^{TL}, 김민제^{TL}, 김유진^{IL}, 한수빈^{IL}, 조성윤^{IL}, 유지연^{IL}, 최주하, 이성영, 문예빈, 박시영, 김찬주, 성인우, 이찬우, 박지은, 김수민, 오윤지, 김찬미, 신지윤, 김민서, 이동민

- *This report was prepared as part of the ELECOURSE 2026 Spring Semester Project.
For educational and research purposes only.*

Abstract

지속적인 혈압 모니터링은 심혈관계 질환의 예방 및 관리에 있어 매우 중요하다. 그러나 기존의 커프(cuff) 기반 혈압 측정 방식은 측정 과정에서의 불편함과 일상생활의 제약으로 인해 연속적인 혈압 모니터링에 적합하지 않다. 본 연구에서는 심전도(Electrocardiography, ECG)와 광용적맥파(Photoplethysmography, PPG) 신호를 기반으로 하는 종단 간(end-to-end) 비커프식(cuffless) 혈압 추정 파이프라인을 개발하였다. 제안된 시스템은 하드웨어 설계, 생체신호 획득, 신호처리, 특징 추출, 머신러닝 기반 혈압 추정 및 실험적 검증 과정을 통합적으로 포함한다. ECG 신호는 AD8232 모듈을 이용하여 획득하였으며, PPG 신호는 MAX30102 센서를 이용하여 측정하였다. 동기화된 ECG 및 PPG 신호로부터 맥파도달시간(Pulse Arrival Time, PAT)과 맥파전달시간(Pulse Transit Time, PTT)을 추출하였으며, 이를 나이, 성별, 신장, 체중과 같은 인구통계학적 특성과 함께 혈압 추정에 활용하였다. 데이터는 건강한 성인 20 명을 대상으로 수집되었으며, 총 84 개의 측정 샘플로 데이터셋을 구축하였다. 혈압 추정을 위해 Support Vector Regression(SVR), Random Forest(RF), Hybrid LASSO-XGBoost 의 세 가지 회귀 모델을 평가하였다. 실험 결과, Hybrid LASSO-XGBoost 모델이 가장 우수한 성능을 보였으며, 수축기 혈압(SBP)과 이완기 혈압(DBP)에 대해 각각 6.90 mmHg 및 6.74 mmHg 의 평균절대오차(Mean Absolute Error, MAE)를 달성하였다. 이러한 결과는 ECG 및 PPG 기반 비침습적 혈압 추정의 실현 가능성을 확인하였으며, 향후 웨어러블 헬스케어 시스템 및 연속 혈압 모니터링 기술 개발에 유용한 시사점을 제공한다.

Continuous blood pressure monitoring is essential for the prevention and management of cardiovascular diseases. Conventional cuff-based blood pressure measurement methods are unsuitable for continuous monitoring due to discomfort and interruption of daily activities. In this study, an end-to-end cuffless blood pressure estimation pipeline based on electrocardiography (ECG) and photoplethysmography (PPG) signals was developed. The proposed system integrates hardware design, biosignal acquisition, signal processing, feature extraction, machine learning-based estimation, and experimental validation. ECG signals were acquired using an AD8232 module, while PPG signals were collected using a MAX30102 sensor. Pulse Arrival Time (PAT) and Pulse Transit Time

(PTT) were extracted from synchronized ECG and PPG signals and used together with demographic features including age, sex, height, and weight. Data were collected from 20 healthy participants, resulting in 84 measurement samples. Three regression models—Support Vector Regression (SVR), Random Forest (RF), and Hybrid LASSO-XGBoost—were evaluated. Experimental results demonstrated that the Hybrid LASSO-XGBoost model achieved the best overall performance, with mean absolute errors of 6.90 mmHg and 6.74 mmHg for systolic and diastolic blood pressure estimation, respectively. The results demonstrate the feasibility of ECG/PPG-based cuffless blood pressure estimation and provide insights for future wearable healthcare applications.

Keywords - Cuffless Blood Pressure Estimation, ECG, PPG, Pulse Transit Time, Pulse Arrival Time, Machine Learning, Wearable Healthcare

1. Introduction

고혈압(hypertension)은 심혈관 질환(cardiovascular disease), 뇌졸중(stroke), 심부전(heart failure), 신부전(kidney failure) 등의 주요 위험 인자로 알려져 있으며, 전 세계적으로 높은 유병률을 보이는 대표적인 만성질환 중 하나이다. 혈압은 개인의 심혈관 건강 상태를 반영하는 핵심 생체 지표(vital sign)로서, 혈압의 지속적인 모니터링은 질병의 조기 발견과 예방뿐만 아니라 환자의 건강 상태를 장기적으로 관리하는 데 중요한 역할을 한다. 특히 최근 고령화 사회의 진전과 생활 습관 변화로 인해 고혈압 환자 수가 증가함에 따라, 일상생활 중에도 지속적으로 혈압을 측정할 수 있는 기술에 대한 관심이 높아지고 있다.

현재 가장 널리 사용되는 혈압 측정 방식은 커프(cuff)를 이용한 오실로메트릭(oscillometric) 방법이다. 그러나 이러한 방식은 측정 과정에서 팔을 압박해야 하므로 사용자의 움직임을 제한하며, 장시간 반복 측정 시 불편함을 유발한다. 또한 측정 시점의 혈압만을 제공하기 때문에 수면 중 혈압 변화, 운동 중 혈압 변화, 스트레스 상황에서의 혈압 변동과 같은 연속적인 생리학적 변화를 관찰하기 어렵다는 한계가 존재한다. 이러한 이유로 최근에는 사용자의 일상생활을 방해하지 않으면서 혈압을 추정할 수 있는 cuffless blood pressure estimation 기술이 차세대 디지털 헬스케어 기술로 주목받고 있다.

웨어러블 헬스케어 기술의 발전과 함께 다양한 생체신호(biosignal)를 활용한 비침습적(non-invasive) 혈압 추정 방법이 연구되고 있다. 그중 ECG(Electrocardiogram)와 PPG(Photoplethysmography)를 동시에 활용하는 방법은 상대적으로 구현이 용이하며 웨어러블 디바이스에 적용하기 적합하다는 장점이 있다. ECG는 심장의 전기적 활동을 측정하는 신호이며, PPG는 광학 센서를 이용하여 말초 혈관에서 발생하는 혈류 변화를 측정하는 신호이다. 두 신호 사이의 시간 차이인 Pulse Arrival Time(PAT) 또는 Pulse Transit Time(PTT)은 혈압과 밀접한 상관관계를 갖는 것으로 알려져 있으며, 이를 이용하여 혈압을 간접적으로 추정할 수 있다. 최근에는 이러한 특징에 머신러닝(machine learning) 및 딥러닝(deep learning) 기법을 결합하여 보다 정확한 혈압 예측 모델을 개발하려는 연구가 활발하게 진행되고 있다.

본 프로젝트는 대학생 전기·전자공학 연합 동아리 ELECOURSE(엘레코스)의 정규 프로젝트 활동의 일환으로 수행되었다. ELECOURSE는 다양한 대학의 학생들이 모여 매 학기 새로운 주제를 선정하고, 하드웨어 설계, 임베디드 시스템, 신호처리, 인공지능, 로보틱스 등 다양한 공학 분야의 프로젝트를 수행하는 학술 동아리이다. 본 학기에는 웨어러블 헬스케어 기술과 인공지능을 융합한 주제로서 cuffless blood pressure estimation 시스템 개발을 선정하였으며, 하드웨어(HW), 신호처리(SP), 머신러닝(ML), 유효성 검증(VL) 파트가 협업하여 프로젝트를 진행하였다.

본 연구에서는 ECG 및 PPG 신호를 동시에 획득할 수 있는 STM32 기반 생체신호 측정 시스템을 설계하고 구현하였다. 또한 수집된 신호에 대해 필터링, R-peak 검출, PPG foot point 검출, PAT/PTT 계산 등의 신호처리 과정을 수행하였으며, 연령(Age), 성별(Gender), 신장(Height), 체중(Weight) 등의 인구통계학적 정보와 결합하여 혈압 예측 모델을 구축하였다. 데이터 수집을 위해 총 20 명의 피험자를 대상으로 반복 측정을 수행하였으며, 최종적으로 84 개의 측정 데이터를 확보하였다.

혈압 예측을 위해 Support Vector Regression(SVR), Random Forest(RF), Hybrid LASSO-XGBoost 모델을 적용하고 성능을 비교하였다. 또한 신호 품질 평가(Signal Quality Index), 데이터 검증(Data Validation), Subject-Independent 검증 기법 등을 도입하여 모델의 일반화 성능과 생리학적 타당성을 평가하였다. 실험 결과 Hybrid LASSO-XGBoost 모델이 가장 우수한 성능을 보였으며, 수축기 혈압(SBP)과 이완기 혈압(DBP)에 대해 각각 6.90 mmHg 와 6.74 mmHg 의 평균 절대 오차(MAE)를 달성하였다.

본 연구의 목적은 제한된 데이터 환경에서도 ECG 및 PPG 기반 cuffless blood pressure estimation 시스템의 구현 가능성을 검증하고, 하드웨어 설계부터 신호처리, 머신러닝 기반 예측 및 유효성 검증에 이르는 전체 파이프라인을 구축하는 데 있다. 또한 본 프로젝트를 통해 향후 웨어러블 헬스케어 기기 및 연속 혈압 모니터링 시스템 개발을 위한 기초 연구 자료를 제공하고자 한다.

2. Materials and Methods

본 프로젝트 연구에서는 ECG(Electrocardiography) 및 PPG(Photoplethysmography) 신호를 활용한 비커프식(cuffless) 혈압 추정 시스템을 개발하고 그 성능을 평가하였다. 제안된 시스템은 생체신호 획득 하드웨어, 신호 전처리, 특징 추출, 머신러닝 기반 혈압 예측 및 성능 검증 단계로 구성된다.

먼저 ECG 및 PPG 센서를 이용하여 피험자의 생체신호를 동기적으로 획득하였으며, 획득된 신호에 대해 필터링 및 노이즈 제거 과정을 수행하였다. 이후 ECG 신호의 R-peak 와 PPG 신호의 특징점을 검출하여 Pulse Arrival Time (PAT) 및 Pulse Transit Time (PTT)을 계산하였다. 또한 연령, 성별, 신장, 체중과 같은 인구통계학적 정보를 추가적인 입력 변수로 활용하였다. 수집된 특징들은 Support Vector Regression (SVR), Random Forest (RF), 그리고 Hybrid LASSO-XGBoost 모델의 입력으로 사용되었으며, 각 모델의 혈압 예측 성능을 비교·평가하였다. 실험은 총 20 명의 건강한 성인을 대상으로 수행되었으며, 수축기 혈압(SBP)과 이완기 혈압(DBP)을 예측 대상으로 설정하였다.

본 장에서는 먼저 생체신호 측정 시스템의 하드웨어 구성을 설명하고, 이후 데이터 수집 과정, 신호처리 및 특징 추출 방법, 머신러닝 모델 구성, 그리고 성능 평가 방법에 대해 순차적으로 기술한다.

2.1. Hardware System Design

본 연구에서는 비커프식(cuffless) 혈압 추정을 위해 ECG(Electrocardiography) 및 PPG(Photoplethysmography) 신호를 동시에 획득할 수 있는 생체신호 측정 시스템을 구축하였다. ECG 신호 획득을 위해 AD8232 모듈을 사용하였으며, PPG 신호 측정을 위해 MAX30102 센서를 적용하였다. 수집된 신호의 통합 관리 및 데이터 전송을 위해 STM32 마이크로컨트롤러를 사용하였다.

AD8232는 단일 리드(single-lead) ECG 측정이 가능한 아날로그 프론트엔드(Analog Front-End, AFE) 모듈로서, 내장 증폭기와 필터를 포함하고 있어 심전도 신호의 안정적인 획득에 적합하다. MAX30102는 적외광(Red LED) 및 적외선(Infrared LED)을 이용하여 혈액량 변화를 측정하는 광학 센서로, 웨어러블 생체신호 측정 시스템에 널리 활용되고 있다. STM32는 다수의 ADC 및 I²C 인터페이스를 제공하여 ECG와 PPG 신호를 동시에 수집하고 처리할 수 있는 장점을 가진다.

시스템의 전체 구성은 AD8232 ECG 센서와 MAX30102 PPG 센서로부터 획득한 신호를 STM32에서 수집한 후, USB Serial 통신을 통해 PC로 전송하는 구조로 설계하였다. ECG 신호는 아날로그 형태로 출력되므로 STM32의 ADC(Analog-to-Digital Converter)를 이용하여 디지털 데이터로 변환하였다. 반면, PPG 신호는 MAX30102 내부에서 디지털 데이터로 처리되며, I²C 통신을 통해 직접 수집하였다. 또한 AD8232의 Lead-off Detection 신호를 STM32 GPIO에 연결하여 전극 접촉 상태를 실시간으로 확인할 수 있도록 구성하였다.

MAX30102는 STM32의 I²C 인터페이스를 통해 연결되었으며, 측정된 PPG 데이터는 ECG 데이터와 함께 STM32 내부에서 동기화 및 저장 과정을 거친 후 USB Serial 통신을 통해 PC로 전송되었다. 이와 같은 통합 구조를 통해 서로 다른 형태의 생체신호를 하나의 플랫폼에서 효율적으로 수집할 수 있도록 하였다. 본 연구에서 사용한 하드웨어 구성은 ECG와 PPG 신호의 동시 측정이 가능하며, 맥파도달시간(Pulse Arrival Time, PAT) 및 맥파전달시간(Pulse Transit Time, PTT) 계산에 필요한 시간 동기화 정보를 제공할 수 있다는 장점을 가진다. 따라서 제안된 시스템은 비침습적 연속 혈압 추정을 위한 생체신호 획득 플랫폼으로 활용될 수 있다.




Fig.1. Overall architecture of the ECG/PPG acquisition system

2.2. Signal Acquisition

ECG 및 PPG 신호는 STM32 기반 임베디드 데이터 수집 시스템을 이용하여 동시 획득하였다. ECG 측정을 위해 AD8232 모듈을 사용하였으며, 전극은 표준 3전극 구성을 적용하여 좌측 흉부, 우측 흉부 및 우측 측복부에 부착하였다. PPG 신호는 MAX30102 센서를 이용하여 손가락 말단에서 측정하였다.

생체신호는 STM32 내부 타이머를 기준으로 약 4 ms 간격으로 수집되었으며, 실제 샘플링 주파수는 약 250 Hz였다. 수집된 데이터는 Timestamp, Sample Index, ECG 원신호, Baseline Drift 제거 ECG 신호, PPG 신호 및 Lead-off 상태 정보를 포함하였다. 각 샘플에는 고유한 Sample Index를 부여하여 데이터 손실 여부를 확인할 수 있도록 하였으며, Timestamp 정보를 이용하여 측정 시점 간의 시간 관계를 유지하였다.

수집된 데이터는 USB Serial 통신을 통해 실시간으로 PC로 전송되었으며, Python 기반 데이터 로깅 프로그램을 이용하여 CSV 형식으로 저장하였다. 또한 AD8232의 Lead-off Detection 기능을 활용하여 전극 접촉 상태를 모니터링함으로써 신뢰성이 확보된 데이터만 분석에 사용하였다.

혈압 추정을 위한 기준값(reference blood pressure)을 확보하기 위해 ECG 및 PPG 측정과 동시에 상용 전자혈압계를 이용하여 수축기 혈압(Systolic Blood Pressure, SBP)과 이완기 혈압(Diastolic Blood Pressure, DBP)을 측정하였다. 또한 연령, 성별, 신장, 체중, 카페인 섭취 여부 및 운동 여부와 같은 피험자 정보를 함께 기록하여 데이터셋을 구성하였다.

모든 측정은 피험자가 편안하게 앉아 있는 안정 상태(resting condition)에서 수행되었으며, 측정 중 발생할 수 있는 움직임에 의한 잡음을 최소화하기 위해 불필요한 신체 움직임을 제한하였다.

2.3. Signal Processing

수집된 ECG 및 PPG 신호는 특징 추출 이전에 전처리 과정을 거쳤다. 먼저 데이터 무결성을 확보하기 위해 Sample Index 를 기준으로 연속성을 확인하였으며, 일정 기준 이상의 데이터 누락이 발생한 구간은 독립적인 세그먼트로 분리하여 처리하였다.

ECG 신호는 직류 성분 제거, 전원 노이즈 제거 및 대역통과 필터링 과정을 수행하였다. 먼저 ECG 신호의 DC Offset 을 제거한 후, 60 Hz Notch Filter 를 적용하여 전원 잡음을 제거하였다. 이후 0.5-40 Hz Butterworth Band-pass Filter 를 적용하여 Baseline Wander 와 고주파 잡음을 억제하였다. 필터링 과정에는 Zero-phase Filtering 기법을 적용하여 위상 왜곡을 최소화하였다.




Fig. 2. Signal Processing and Feature Extraction Pipeline

PPG 신호는 맥파 특징점 검출을 위한 전처리 과정으로 0.5-7 Hz Butterworth Band-pass Filter를 적용하였다. 이를 통해 호흡 및 움직임에 의한 저주파 성분과 고주파 잡음을 동시에 제거하여 PPG 파형의 상승부와 Foot Point를 보다 명확하게 추출할 수 있도록 하였다.

2.4. Feature Extraction

혈압 추정을 위한 주요 특징(feature)으로 ECG 신호의 R-peak와 PPG 신호의 Foot Point를 추출하였다. 이후 두 특징점을 이용하여 Pulse Arrival Time (PAT) 및 Pulse Transit Time (PTT)를 계산하였다. 전체 특징 추출 과정은 ECG R-peak 검출, PPG Foot Point 검출, PAT/PTT 계산 및 데이터 검증 단계로 구성된다.

2.4.1 ECG R-Peak Detection

ECG R-peak 검출은 필터링된 ECG 신호를 입력으로 수행하였다. 본 연구에서는 Pan-Tompkins 알고리즘과 유사한 구조를 적용하여 QRS Complex를 강조하고 R-peak를 검출하였다.

먼저 ECG 신호를 미분(Derivative)하여 QRS Complex와 같이 급격한 변화가 발생하는 구간을 강조하였다. 이후 미분 신호를 제곱(Squaring)하여 모든 값을 양수화하고, 큰 변화량이 더욱 크게 반영되도록 하였다. 다음으로 이동 평균 적분(Moving Window Integration)을 수행하여 QRS 에너지 신호를 생성하였다. 이동 평균 윈도우 길이는 0.12 s로 설정하였다.

생성된 QRS 에너지 신호에 대해 평균값과 표준편차를 이용한 동적 임계값(Dynamic Threshold)을 설정하였다. 설정된 임계값을 초과하는 Peak를 R-peak 후보로 선정하였다.

그러나 QRS 에너지 신호에서 검출된 후보 Peak는 실제 ECG 상의 R-peak 위치와 차이가 발생할 수 있다. 이를 보정하기 위해 각 후보 Peak 주변 ± 0.08 s 범위에서 필터링된 ECG 신호의 국소 최댓값(Local Maximum)을 탐색하였다. 해당 지점을 최종 R-peak 위치로 결정하였으며, 검출된 R-peak 수가 최소 기준 이상인 경우에만 해당 구간을 유효한 ECG 신호로 판단하였다.

2.4.2 PPG Foot Point Detection

PPG Foot Point 검출은 독립적인 Peak Detection 방식이 아니라 ECG R-peak를 기준으로 수행하였다. 이는 ECG와 PPG 사이의 생리학적 시간 관계를 활용하여 오검출 가능성을 줄이기 위함이다.

먼저 필터링된 PPG 신호를 1차 미분하여 Velocity Photoplethysmogram (VPG)을 계산하고, 다시 미분하여 Acceleration Photoplethysmogram (APG)을 생성하였다. 실제 Foot Point 검출에는 주로 VPG 정보를 활용하였다. 각 ECG R-peak 이후 0.10-0.45 s 구간을 PPG Foot Point 탐색 구간으로 설정하였다. 이는 ECG 전기적 활성 이후 말초 혈관에서 맥파가 관측되기까지의 일반적인 지연 시간을 반영한 것이다.

탐색 구간 내에서 VPG 값이 최대가 되는 지점을 Maximum Slope Point로 정의하였다. 이후 해당 지점의 앞쪽 0.06 s 범위 내에서 PPG 진폭이 가장

작은 지점을 Local Minimum 으로 탐색하였다. 최종 Foot Point 는 Tangent Intersection 방법을 이용하여 계산하였다. Maximum Slope Point 에서의 접선과 Local Minimum 에서의 기준 진폭선이 만나는 지점을 Foot Point 로 정의하였다. 이 방법은 단순한 최소값 기반 검출보다 PPG 상승부의 형상을 효과적으로 반영할 수 있다는 장점을 가진다.

2.4.3 PAT/PTT Calculation

PAT 및 PTT 계산은 ECG R-peak 와 PPG Foot Point 가 동일한 Beat 에 대해 매칭된 이후 수행하였다. 먼저 인접한 R-peak 사이의 시간 차이를 이용하여 RR Interval 을 계산하였다. PAT 는 ECG R-peak 시점과 PPG Foot Point 시점의 차이로 정의하였다.

$$PAT = t_{foot} - t_R$$

여기서 t_R 은 ECG R-peak 발생 시점이며, t_{foot} 은 대응되는 PPG Foot Point 발생 시점이다. PTT 는 PAT 에서 Pre-Ejection Period (PEP)를 제외한 값으로 정의하였다.

$$PTT = PAT - PEP$$

본 연구에서는 PEP 를 직접 측정하지 못하였으므로 문헌에서 보고된 평균값을 참고하여 70 ms 의 고정값을 사용하였다. 따라서 실제 계산에는 다음 식을 적용하였다.

$$PTT_{ms} = PAT_{ms} - 70$$

계산된 결과는 Beat 단위 Feature Table 로 저장하였으며, 주요 변수로는 R-peak Index, Foot Point Index, R-peak Time, Foot Point Time, RR Interval, PAT 및 PTT 를 포함하였다.

2.4.4 Data Validation

PAT 및 PTT 계산 결과의 신뢰성을 확보하기 위하여 생리학적 타당성 검증(Data Validation)을 수행하였다. 첫 번째 단계에서는 절대 범위 검사를 수행하였다. PEP, PAT 및 PTT 가 사전에 정의된 생리학적 범위를 벗어나는 경우 해당 Beat 를 제거하였다. 본 연구에서 사용한 범위는 PEP 20-180 ms, PAT 150-450 ms 및 PTT 80-380 ms 이다.

두 번째 단계에서는 중앙값(Median) 기반 이상치 검출을 수행하였다. PAT 와 PTT 가 동일 세그먼트 내 중앙값에서 과도하게 벗어나는 경우 이상치로 판단하였다. PAT 는 중앙값의 $\pm 15\%$ 또는 최소 30 ms, PTT 는 중앙값의 $\pm 20\%$ 또는 최소 30 ms 를 기준으로 적용하였다.

세 번째 단계에서는 Beat-to-Beat 변화량 검사를 수행하였다. 인접한 Beat 간 PAT 또는 PTT 변화량이 55 ms 를 초과하는 경우 비정상적인 검출로 간주하여 제거하였다. 마지막으로 RR Interval 이 해당 세그먼트의 중앙값 기준 $\pm 30\%$ 범위를 벗어나는 경우를 제거하였다. 모든 검증 조건을 만족한 Beat 만 최종 Feature Extraction 결과로 채택하였다.

2.5. Machine Learning Models

본 연구의 최종 목표는 ECG 및 PPG 신호로부터 추출된 생체신호 특징과 인구통계학적 정보를 이용하여 수축기 혈압(Systolic Blood Pressure, SBP) 및 이완기 혈압(Diastolic Blood Pressure, DBP)을 예측하는 것이다. 이를 위해

Age, Gender, Height, Weight, PAT, PTT 를 입력 변수(feature)로 사용하였으며, SBP 와 DBP 를 각각 회귀(regression) 문제로 정의하여 머신러닝 모델을 학습하였다.

2.5.1 Dataset Construction

초기 개발 단계에서는 머신러닝 파이프라인의 정상 동작 여부를 검증하기 위하여 인위적으로 생성한 비선형 함수 기반 데이터셋을 활용하였다. 이후 공개 데이터셋을 조사하였으나, 본 연구에서 요구하는 모든 변수(SBP, DBP, PAT, PTT, Height, Weight, Gender)를 동시에 포함하는 데이터셋을 확보하지 못하였다. 따라서 연구팀은 자체 데이터셋 구축을 수행하였다. 총 20 명의 건강한 성인을 대상으로 ECG 및 PPG 신호를 측정하였으며, 각 피험자에 대해 반복 측정을 수행하여 총 84 개의 샘플을 확보하였다. 각 샘플에는 SBP, DBP, Age, Gender, Height, Weight, PAT 및 PTT 정보가 포함되었다. 데이터 부족 문제를 완화하기 위해 일부 실험에서는 데이터 증강(Data Augmentation)을 적용하였다. 증강 데이터는 기존 데이터의 통계적 특성을 유지하는 범위 내에서 생성되었으며, 증강 전후의 성능 차이를 비교하여 데이터 증강의 효과를 평가하였다.

2.5.2 Support Vector Regression (SVR)

Support Vector Regression(SVR)은 Support Vector Machine(SVM)에 기반한 회귀 모델로, 입력 변수와 목표 변수 간의 관계를 최대 마진(maximum margin) 기반으로 학습한다. 본 연구에서는 방사 기저 함수(Radial Basis Function, RBF) 커널을 사용하여 PAT 및 PTT 와 혈압 사이의 비선형 관계를 모델링하였다. SVR 은 비교적 적은 수의 학습 데이터에서도 안정적인 성능을 보이며 과적합 위험이 낮다는 장점이 있다. 또한 생체신호와 혈압 사이의 복잡한 비선형 관계를 효과적으로 학습할 수 있어 본 연구의 비교 모델로 선정하였다.

주요 하이퍼파라미터는 다음과 같다.

- C: 오차에 대한 패널티 계수
- ϵ (epsilon): 허용 오차 범위
- γ (gamma): RBF 커널의 영향 범위
- cv: 교차 검증 횟수
- n_iter: RandomizedSearchCV 탐색 횟수

최적의 하이퍼파라미터는 RandomizedSearchCV 를 이용하여 탐색하였다.

2.5.3 Random Forest

Random Forest(RF)는 다수의 의사결정나무(Decision Tree)를 앙상블하여 예측을 수행하는 회귀 모델이다. 각 트리는 무작위로 선택된 데이터 및 특징 집합을 이용하여 독립적으로 학습되며, 최종 예측값은 모든 트리의 평균값으로 계산된다. RF 는 변수 간 비선형 관계를 효과적으로 모델링할 수 있으며, 변수 중요도(Feature Importance)를 제공하여 모델의 설명 가능성을 확보할 수 있다는 장점이 있다. 따라서 PAT, PTT 등의 특징이 혈압 예측에 미치는 영향을 분석하기 위한 비교 모델로 활용하였다.

주요 하이퍼파라미터는 다음과 같다.

- `n_estimators`: 의사결정나무 개수
- `max_depth`: 트리 최대 깊이
- `min_samples_split`: 노드 분할 최소 샘플 수
- `random_state`: 난수 시드
- `n_trials`: Optuna 기반 최적화 반복 횟수

하이퍼파라미터 최적화는 Optuna 프레임워크를 이용하여 수행하였다.

2.5.4 Hybrid LASSO-XGBoost

본 연구에서는 선형 모델과 비선형 모델의 장점을 결합하기 위하여 Hybrid LASSO-XGBoost 모델을 제안하였다. LASSO는 선형 회귀에 L1 정규화(L1 Regularization)를 적용한 모델로, 불필요한 특징의 계수를 0으로 수렴시켜 특징 선택 효과를 제공한다. XGBoost는 Gradient Boosting 기반의 트리 앙상블 모델로, 복잡한 비선형 관계를 효과적으로 학습할 수 있다.

제안된 Hybrid 모델은 두 단계로 구성된다. 먼저 LASSO 모델이 입력 특징으로부터 혈압의 선형 성분을 학습한다. 이후 LASSO가 설명하지 못한 잔차(residual error)를 XGBoost가 추가적으로 학습하여 최종 예측값을 생성한다. 이를 통해 선형 모델의 과소적합(underfitting) 문제와 비선형 모델의 과적합(overfitting) 문제를 동시에 완화할 수 있도록 하였다.

LASSO 모델의 주요 하이퍼파라미터는 α (Regularization Strength), 최대 반복 횟수(max_iter), 허용 오차(tolerance)이며, XGBoost 모델의 주요

하이퍼파라미터는 `n_estimators`, `learning_rate`, `max_depth`, `subsample`, `colsample_bytree`, `reg_alpha` 및 `reg_lambda` 이다. 각 모델의 최적 하이퍼파라미터는 교차 검증 기반 RandomizedSearchCV를 통해 결정하였다.

2.5.5 Training and Evaluation Procedure

모든 모델 학습 이전에 결측치 및 이상치를 제거하여 데이터셋을 정제하였다. 이후 데이터는 학습용(training)과 검증용(test)으로 분할되었으며, 모델에 따라 Internal Split, Leave-One-Group-Out(LOGO) 교차검증 및 External Test 방식을 적용하였다.

SVR과 Hybrid 모델은 입력 변수의 단위 차이에 따른 영향을 줄이기 위해 Standard Scaling을 적용하였다. Random Forest는 트리 기반 모델의 특성상 별도의 스케일링 없이 학습을 수행하였다.

모델 학습 과정에서는 Grid Search, Randomized Search 및 Optuna 기반 하이퍼파라미터 최적화를 수행하였다. 학습이 완료된 모델은 검증 데이터에 대해 SBP 및 DBP를 예측하였으며, 예측 성능은 평균절대오차(MAE), 평균 오차율(Mean Error), 평균제곱오차(MSE), 결정계수(R^2)를 이용하여 평가하였다.

또한 모델의 특성을 분석하기 위해 Predicted-versus-Actual Plot, Error Distribution, Correlation Heatmap 및 Feature Importance를 함께 분석하였다.




Fig.3. SVR Model Prediction Result




Fig.4. Random Forest Model Prediction Result




Fig.5. Hybrid Lasso + XGBoost Model Prediction Result

2.6. Experimental Protocol and Validation Criteria

본 연구에서는 ECG 및 PPG 기반 비침습 혈압 추정 시스템의 신뢰성을 확보하기 위하여 측정 환경, 피험자 조건, 신호 품질 관리 및 성능 평가 기준을 체계적으로 설계하였다. 특히 생리학적 변수와 환경적 요인이 혈압 및 생체신호에 미치는 영향을 최소화하기 위하여 표준화된 측정 프로토콜을 적용하였다.

2.6.1 Subject Selection and Measurement Conditions

피험자는 심혈관계 질환 또는 고혈압 병력이 없는 건강한 성인을 대상으로 모집하였다. 피험자 간 기초 혈액학적 상태의 차이를 최소화하기 위하여 연령 범위를 20~25 세로 제한하였다.

측정 전 혈압에 영향을 줄 수 있는 외부 요인을 통제하기 위해 모든 피험자에게 측정 전 30 분 이내의 카페인 섭취, 흡연 및 격렬한 운동을 금지하도록 안내하였다. 또한 방광 팽창에 의한 교감신경계 자극 효과를 배제하기 위해 측정 전 배뇨를 완료하도록 하였다.

모든 측정은 실내 환경에서 수행되었으며, 피험자는 등반이가 있는 의자에 편안히 앉은 자세를 유지하였다. 혈류 역학적 변화가 발생할 수 있는 다리 꼬기 자세는 금지하였으며, 센서가 부착된 팔은 심장과 동일한 높이에 위치하도록 하였다. 데이터 수집 전 최소 5 분간 안정 상태를 유지한 후 측정을 시작하였으며, 각 피험자에 대해 3 회 이상의 반복 측정을 수행하였다.

2.6.2 Measurement Environment Control

생체신호 측정 과정에서 발생할 수 있는 외부 잡음을 최소화하기 위해 측정 중 대화, 스마트폰 사용 및 불필요한 움직임을 제한하였다. 또한 PPG 센서의 광학적 간섭을 줄이기 위해 외부광을 차단하였으며, 전자기적 잡음을 감소시키기 위해 센서 연결 상태와 신호 전송 환경을 지속적으로 확인하였다.

2.6.3 Signal Quality Assessment and Data Rejection

수집된 데이터의 품질을 정량적으로 평가하기 위하여 Signal Quality Index (SQI) 기반 검증 절차를 적용하였다. PPG 신호는 템플릿 매칭, 왜도(Skewness), 첨도(Kurtosis) 및 영교차율(Zero-Crossing Rate)을 이용하여 품질을 평가하였다. ECG 신호는 복수의 R-peak 검출 결과를 비교하여 검출 일치도를 산출함으로써 신뢰도를 평가하였다.

또한 다음 조건에 해당하는 데이터는 분석에서 제외하였다.

1. 신호 포화(Clipping)로 인해 파형이 일정 시간 이상 평탄하게 유지되는 경우
2. SQI 점수가 사전에 정의한 기준 이하인 경우
3. 계산된 심박수가 생리학적으로 타당하지 않은 범위에 위치하는 경우
4. Motion Artifact, 전극 접촉 불량 또는 외부 간섭에 의해 파형이 심각하게 왜곡된 경우

이를 통해 신뢰성이 확보된 데이터만 머신러닝 모델 학습 및 평가에 사용하였다.

2.6.4 Physiological Interpretation of PTT

본 연구는 Pulse Transit Time (PTT)와 혈압 사이의 관계가 혈관 탄성도 및 맥파 전달 속도에 의해 결정된다는 가정에 기반한다. 이러한 관계는 Moens-Korteweg 방정식으로 설명될 수 있으며, 혈압이 증가할수록 혈관 탄성 변화에 의해 맥파 전달 속도가 증가하고 PTT는 감소하는 경향을 나타낸다.

그러나 실제 환경에서는 혈관 직경, 혈관 탄성도, 자율신경계 상태 및 개인별 생리학 특성에 의해 이러한 관계가 달라질 수 있으므로, 본 연구에서는 PTT 뿐 아니라 연령, 성별, 신장 및 체중 정보를 함께 활용하여 혈압을 추정하였다.

2.6.5 Performance Evaluation Criteria

모델 성능 평가는 평균절대오차(Mean Absolute Error, MAE), 평균제곱근오차(Root Mean Square Error, RMSE), 평균 오차(Mean Error) 및 결정계수(R^2)를 이용하여 수행하였다. 본 연구에서 사용한 모델에 대한 적합성 판단 결과는 Table 1에 첨부하였다.

특히 결과 해석 시 국제 비침습 혈압계 평가 기준인 ISO 81060-2를 참고하였다. 해당 기준은 평균 오차가 5 mmHg 이하이고 오차의 표준편차가 8 mmHg 이하일 것을 요구한다. 따라서 본 연구에서는 단순한 상대 오차율뿐만 아니라 절대 오차(mmHg) 기반의 평가를 함께 수행하여 임상적 활용 가능성을 검토하였다.

또한 Subject-Independent 평가를 위해 Leave-One-Subject-Out 방식의 교차검증을 적용하였다. 이를 통해 동일 피험자의 데이터가 학습 및 평가에 동시에 사용되는 데이터 누수(Data Leakage)를 방지하고, 실제 신규 사용자에게 대한 일반화 성능을 평가하였다.

Table 1
Algorithm Validation Results

데이터셋 환경 (증강 여부)	알고리즘	VL 파트 검증 결과 (지표 및 특이사항)	판정
Dataset(3)_60 (증강 X)	SVR	데이터 부족으로 인한 생체 신호 패턴 학습 실패 Trend 상실	Reject
Dataset(3)_110 (증강 X)	Random Forest	feature 중요도 분석 결과 overfitting 으로 판단됨 인구통계학적 변수 의존	Reject
Dataset(3)_100 (증강 O)	LASSO + XGBoost	실제 혈압 이상향 추세 추종 성공 SBP/DBP 오차율 1-5% 구간 밀집	Pass

3. Results

본 장에서는 ECG 및 PPG 기반 cuffless blood pressure estimation 시스템의 구현 결과와 데이터 처리 결과, 그리고 머신러닝 기반 혈압 예측 성능을

제시한다. 결과는 신호 획득, 특징 추출, 혈압 추정 성능 및 모델 비교의 순서로 기술하였다.

3.1. Signal Acquisition Results

본 연구에서는 STM32 기반의 생체신호 수집 시스템을 구축하여 ECG 및 PPG 신호를 동시에 획득하였다. 시스템은 AD8232 ECG 센서와 MAX30102 PPG 센서를 이용하여 약 250 Hz의 샘플링 주파수로 데이터를 수집하였으며, 모든 데이터에는 Timestamp와 Sample Index를 함께 저장하여 후속 신호처리 및 동기화에 활용하였다.

초기 개발 과정에서는 ECG 신호의 baseline drift, PPG 센서 통신 오류, I2C 인터페이스 불안정성 등의 문제가 발생하였다. 특히 MAX30102 센서는 STM32의 I2C1 인터페이스에서 안정적으로 동작하지 않아 I2C3 채널로 변경하였으며, 이후 정상적인 데이터 수집이 가능하였다. 또한 ECG 전극의 접촉 상태를 실시간으로 확인하기 위하여 Lead-off Detection 기능을 추가하였다.

최종적으로 구축된 시스템은 ECG 원신호와 baseline drift 제거 신호를 동시에 저장할 수 있었으며, 장시간 측정에서도 안정적으로 ECG 및 PPG 데이터를 수집할 수 있었다. 수집된 데이터는 USB Serial 통신을 통해 실시간으로 PC에 전송되었으며 CSV 형식으로 저장되어 후속 신호처리 및 머신러닝 학습에 활용되었다.

프로젝트 수행 과정에서 다음과 같은 주요 소프트웨어 산출물을 개발하였다.

- ECG/PPG Filtering Module
- PAT/PTT Extraction Module
- Signal Validation Module
- Feature Extraction Module
- Blood Pressure Estimation Module

3.2 PAT/PTT Extraction Results

수집된 ECG 및 PPG 신호에 대해 제안한 신호처리 파이프라인을 적용하여 R-peak와 PPG foot point를 검출하였다. ECG 신호는 60 Hz notch filter와 0.5-40 Hz band-pass filter를 적용한 후 Pan-Tompkins 기반 알고리즘을 이용하여 R-peak를 검출하였다. PPG 신호는 0.5-7 Hz band-pass filter를 적용한 후 VPG 기반 foot detection 알고리즘을 이용하여 foot point를 검출하였다.

검출된 R-peak와 PPG foot point를 beat 단위로 매칭하여 PAT 및 PTT를 계산하였다. 이후 생리학적으로 비정상적인 값을 제거하기 위하여 Data Validation 과정을 수행하였다. Validation 단계에서는 PAT, PTT, RR interval의 허용 범위 검사, 중앙값 기반 이상치 제거 및 beat-to-beat 변화량 검사를 적용하였다.

최종적으로 각 beat에 대해 다음 특징(feature)을 생성하였다.

- PAT (Pulse Arrival Time)
- PTT (Pulse Transit Time)
- RR Interval
- Age

- Gender
- Height
- Weight

이들 특징은 이후 혈압 추정 모델의 입력 변수로 사용되었다.

총 20 명의 피험자로부터 84 회의 유효 측정 데이터를 확보하였으며, 모든 데이터는 데이터 검증 절차를 통과한 후 머신러닝 모델 학습 및 평가에 사용되었다.

3.3 Blood Pressure Estimation Results

혈압 추정을 위하여 SVR, Random Forest 및 Hybrid LASSO-XGBoost 모델을 학습하였다. 입력 변수로는 Age, Gender, Height, Weight, PAT 및 PTT 를 사용하였으며, 출력 변수는 SBP 와 DBP 로 설정하였다. 모델 성능 평가는 Mean Absolute Error (MAE), Mean Error(%), Mean Squared Error (MSE) 및 결정계수(R^2)를 이용하여 수행하였다.

3.3.1 SVR Performance

SVR 모델의 성능은 Table 2 에 나타내었다.

Table 2

Metric	SBP	DBP
MAE (mmHg)	7.75	5.71
R^2	0.362	0.493
Mean Error (%)	7.17	8.24

SVR 모델은 DBP 예측에서 상대적으로 우수한 성능을 보였으며, SBP 와 DBP 모두에서 양의 R^2 값을 나타내어 실제 혈압 변화 경향을 일정 수준 반영할 수 있음을 확인하였다. 한편 데이터 증강(Data Augmentation)을 적용한 경우 성능이 오히려 Table 3 과 같이 감소하는 결과가 관찰되었다.

Table 3

Metric	SBP	DBP
MAE (mmHg)	15.10	11.91
R^2	-2.262	-2.221
Mean Error (%)	12.04	16.98

3.3.2 Random Forest Performance

Random Forest 모델은 Leave-One-Group-Out(LOGO) 교차검증을 적용하여 평가하였다. 모델의 성능은 Table 4 에 나타내었다.

Table 4

Metric	SBP	DBP
MAE (mmHg)	8.94	8.94
R^2	0.21	-0.38
Mean Error (%)	8.77	14.52

Random Forest 모델은 SBP 예측에서는 제한적인 설명력을 보였으나, DBP 예측에서는 음의 R^2 값을 나타내어 충분한 일반화 성능을 확보하지 못하였다. Feature Importance 분석 결과, 체중(Weight)과 연령(Age)이 상대적으로 높은 중요도를 나타냈으며, PAT 및 PTT 의 기여도는 제한적으로 나타났다.

3.3.3 Hybrid LASSO-XGBoost Performance

Hybrid LASSO-XGBoost 모델은 LASSO 를 이용하여 선형 관계를 먼저 학습한 후, 잔차(residual error)를 XGBoost 가 추가적으로 학습하는 구조로 구현하였다. 평가 결과 세 가지 모델 중 가장 우수한 성능을 나타냈다. 모델의 성능은 Table 5 에 나타내었다.

Table 5

Metric	SBP	DBP
MAE (mmHg)	6.90	6.74
Mean Error (%)	약 5% 수준	약 5% 수준

Hybrid 모델은 SBP 와 DBP 모두에서 가장 낮은 MAE 를 기록하였으며, 실제 혈압 변화 추세를 가장 안정적으로 추종하는 결과를 나타냈다.

4. Discussion

본 연구에서는 ECG 및 PPG 신호 기반의 cuffless blood pressure estimation 시스템을 구현하고, 신호 획득부터 특징 추출, 머신러닝 기반 혈압 예측 및 성능 검증까지의 전 과정을 통합적으로 수행하였다. 총 20 명의 피험자로부터 84 개의 측정 데이터를 수집하였으며, PAT, PTT 및 인구통계학적 정보를 이용하여 SBP 와 DBP 를 추정하였다. 실험 결과 Hybrid LASSO-XGBoost 모델이 가장 우수한 성능을 나타냈으며, SVR 과 Random Forest 모델은 상대적으로 낮은 일반화 성능을 보였다.

4.1. Effectiveness of PAT/PTT-Based Blood Pressure Estimation

본 연구에서 사용된 PAT 와 PTT 는 ECG 와 PPG 신호 간의 시간적 관계를 나타내는 대표적인 혈압 관련 특징(feature)이다. 일반적으로 혈압이 증가하면 혈관 강성이 증가하여 맥파 전달 속도가 빨라지고, 이에 따라 PTT 가 감소하는 경향이 알려져 있다. 이러한 생리학적 관계를 기반으로 본 연구에서는 PAT 및 PTT 를 핵심 특징으로 사용하였다.

실험 결과 모든 모델에서 일정 수준 이상의 혈압 추정 성능이 확인되었으며, 이는 ECG/PPG 기반 비침습 혈압 추정의 가능성을 뒷받침한다. 그러나 PAT 와 PTT 만으로는 개인의 절대 혈압 수준을 완전히 설명하기 어려웠다. 특히 새로운 피험자에 대한 예측 과정에서 모델 성능이 크게 저하되는 현상이 관찰되었으며, 이는 혈압이 단순히 맥파 전달 시간뿐 아니라 혈관 탄성도, 말초 저항, 자율신경계 상태 등 다양한 생리학적 요인의 영향을 받기 때문으로 판단된다.

4.2. Machine Learning Model Comparison

본 연구에서는 SVR, Random Forest, Hybrid LASSO-XGBoost 의 세 가지 회귀 모델을 비교하였다.

SVR 은 소규모 데이터셋에서도 비교적 안정적인 성능을 보였으며, DBP 예측에서 가장 낮은 MAE 를 기록하였다. 그러나 데이터 증강을 적용한 경우 성능이 오히려 감소하였다. 이는 RBF 커널 기반 SVR 이 데이터 간 거리 구조에 민감하기 때문에, 실제 생리학적 분포를 충분히 반영하지 못하는 합성 데이터가 노이즈로 작용했기 때문으로 해석된다.

Random Forest 모델은 비선형 관계를 학습할 수 있다는 장점이 있었으나, Feature Importance 분석 결과 체중과 연령에 과도하게 의존하는 경향을 보였다. 반면 핵심 생리학적 변수인 PAT 와 PTT 의 중요도는 상대적으로 낮게 나타났다. 이는 모델이 혈압의 생리학적 메커니즘을 학습하기보다는 특정 피험자의 특성을 암기하는 방향으로 학습되었음을 시사하며, 소규모 데이터 환경에서 발생하는 과적합(overfitting)의 전형적인 사례로 해석할 수 있다.

Hybrid LASSO-XGBoost 모델은 세 모델 중 가장 우수한 성능을 보였다. LASSO 는 선형적 관계를 먼저 학습하여 불필요한 변수를 제거하고, XGBoost 는 잔여 오차를 학습하여 비선형 관계를 보완한다. 이러한 구조는 소규모 데이터셋 환경에서 발생할 수 있는 과적합과 과소적합을 동시에 완화하는 효과를 제공하였다. 실제로 Hybrid 모델은 SBP 와 DBP 모두에서 가장 낮은 평균 절대 오차를 기록하였으며, 혈압 변화 추세를 가장 안정적으로 추종하였다.

4.3. Validation Strategy and Clinical Interpretation

본 연구에서는 단순한 예측 정확도 평가를 넘어 생리학적 타당성과 임상적 활용 가능성을 고려한 검증 체계를 구축하였다. 데이터 수집 단계에서는 카페인 섭취, 운동, 자세 변화 등 혈압에 영향을 미칠 수 있는 요인을 통제하였으며, 신호 품질 평가(SQI) 및 Data Reject 기준을 적용하여 신뢰성 있는 데이터만을 분석에 활용하였다.

또한 모델 검증 과정에서는 Leave-One-Group-Out(LOGO) 교차검증을 활용하여 학습 과정에 사용되지 않은 새로운 피험자에 대한 성능을 평가하였다. 이는 일반적인 무작위 데이터 분할 방식에서 발생할 수 있는 데이터 누수(data leakage)를 방지하고, 실제 웨어러블 환경에서의 일반화 성능을 보다 엄격하게 평가하기 위한 목적이었다.

임상적 관점에서는 AAMI/ESH/ISO 81060-2 기준을 참고하여 결과를 해석하였다. Hybrid 모델은 비교적 우수한 MAE 를 달성하였으나, 일부 샘플에서 큰 오차가 발생하여 임상 등급의 혈압 측정 장비 수준에는 아직 도달하지 못하였다. 특히 DBP 예측에서 관찰된 이상치는 향후 상용화를 위해 해결해야 할 중요한 과제로 판단된다.

4.4. Limitations and Future Work

본 연구는 다음과 같은 한계를 가진다.

첫째, 데이터셋 규모가 제한적이었다. 총 20 명의 피험자와 84 개의 측정 데이터는 머신러닝 모델의 일반화 성능을 확보하기에 충분하지 않았다. 특히 LOGO 검증 방식에서는 매 fold 마다 학습 데이터가 더욱 감소하여 모델 학습의 한계가 존재하였다.

둘째, 혈압 측정 기준값(reference BP)은 상용 혈압계를 이용하여 획득되었으며, 생체신호 측정 시점과 완전히 일치하지 않았다. 이로 인해 기준 혈압 자체에 시간적 변동성이 포함될 가능성이 존재한다.

셋째, 본 연구에서 사용한 특징은 PAT, PTT 및 기본적인 인구통계학적 변수에 한정되었다. 혈관 탄성도, 맥파 형태학적 특징, 심박변이도(HRV) 등의 추가적인 생리학적 정보를 포함한다면 예측 성능 향상이 가능할 것으로 기대된다. 향후 연구에서는 데이터셋 규모 확대, 신호 품질 평가 고도화, 추가 생리학적 특징 도입, 그리고 개인별 초기 보정(calibration) 기법을 적용하여 혈압 예측 정확도와 일반화 성능을 향상시킬 계획이다. 또한 절대 혈압값 예측뿐 아니라 개인별 혈압 변화량 추적 관점의 접근도 유망한 연구 방향이 될 것으로 판단된다.

5. Conclusion

본 연구에서는 동기화된 ECG 및 PPG 신호를 기반으로 하는 종단 간(end-to-end) cuffless blood pressure estimation 시스템을 구현하였다. 제안된 시스템은 생체신호 획득 하드웨어, 신호처리 파이프라인, 특징 추출 알고리즘, 머신러닝 기반 혈압 예측 모델 및 검증 체계를 통합적으로 포함한다. 총 20 명의 피험자로부터 84 개의 측정 데이터를 수집하여 분석하였으며, PAT 와 PTT 를 포함한 생체신호 특징과 인구통계학적 정보를 활용하여 SBP 와 DBP 를 추정하였다.

세 가지 회귀 모델(SVR, Random Forest, Hybrid LASSO-XGBoost)을 비교한 결과, Hybrid LASSO-XGBoost 모델이 가장 우수한 성능을 나타냈으며 SBP 와 DBP 에 대해 각각 6.90 mmHg 와 6.74 mmHg 의 평균 절대 오차를 달성하였다. 이는 ECG/PPG 기반 비침습 혈압 측정의 실현 가능성을 확인한 결과로 평가된다.

또한 본 연구를 통해 PAT 및 PTT 기반 혈압 추정의 가능성과 동시에 한계점도 확인할 수 있었다. 특히 새로운 피험자에 대한 일반화 성능 확보, 데이터 규모 확대, 생리학적 특징 확장 및 개인 맞춤형 보정 기법의 필요성이 확인되었다. 이러한 결과는 향후 웨어러블 기반 연속 혈압 모니터링 시스템 개발을 위한 중요한 기술적 기반을 제공한다.

비록 현재의 성능은 ISO 81060-2 와 같은 임상 등급 기준을 완전히 만족하지는 못하지만, 본 연구는 하드웨어 설계부터 신호처리, 머신러닝 모델링, 임상적 검증에 이르는 전 과정을 통합적으로 구현하였다는 점에서 의의를 가진다. 향후 데이터셋 확대와 알고리즘 고도화를 통해 보다 정확하고 신뢰성 높은 cuffless blood pressure estimation 시스템으로 발전시킬 수 있을 것으로 기대된다.

Acknowledgements

본 연구의 데이터 수집 과정에 자발적으로 참여해 주신 모든 피실험자들에게 깊이 감사드립니다. 또한 하드웨어 설계, 신호처리, 머신러닝 모델 개발 및 유효성 검증 과정에 기여한 모든 팀원들에게 감사의 뜻을 전한다.

Author Contributions

이은설^{1*} 하드웨어 팀장으로서 ECG 및 PPG 동기 측정을 위한 하드웨어 시스템 아키텍처를 설계하였다. AD8232 ECG 모듈, MAX30102 PPG 센서, STM32 마이크로컨트롤러를 통합한 데이터 수집 시스템을 구축하였으며, 센서 인터페이스 및 전원 설계를 총괄하였다. 또한 하드웨어-소프트웨어 연동 구조를 설계하고 시스템 안정성 검증을 수행하였다.

김유진^{1*}, **최주하**, **이성영**, **문예빈**, **박시영**, **김찬주** ADC 및 I2C 기반 ECG/PPG 데이터 수집 기능을 구현하였으며, 타이머 기반 샘플링 구조를 구현하여

데이터 수집 주기의 안정성을 확보하였다. ECG 전극 배치 및 PPG 센서 장착 환경을 최적화하였으며, 측정 과정에서 발생하는 노이즈 및 접촉 불량 문제를 분석하였다. Lead-off Detection 기능 검증과 센서 성능 평가를 수행하여 데이터 품질 향상에 기여하였다.

정성현^{TL} 신호처리 팀장으로서 ECG/PPG 의 핵심 개념과 신호 특성을 선제적으로 학습하고 정리하여 팀의 프로젝트 이해도를 높이고 개발 착수 속도를 향상시켰다. 이론적 신호처리 구조와 파이프라이닝 기반 설계 방향 제시를 통해 시스템의 완성도를 높였으며, 역할을 세분화 및 코드 설계 병렬화로 개발 효율을 극대화하였다. 팀 간 협업 과정에서 인터페이스 및 연동 방식 등의 주요 협의 사항을 조율하며 프로젝트의 원활한 진행에 기여하였다.

조성윤^{IL} ECG 및 PPG 데이터의 시간 동기화와 데이터 포맷 표준화를 담당하였다. 모든 측정 데이터에 sample index 와 timestamp 를 함께 기록하는 데이터 구조를 제안하여 센서 간 공통 시간축을 확보하였으며, 이를 기반으로 세그먼트 분할 및 샘플링 주기 보정 기능을 구현하였다. 또한 하드웨어 팀과 데이터 수집 포맷을 조율하고, 샘플 주기 변경(13→4 ms), DC 제거 위치 협의, 데이터 품질 피드백의 과정을 수행했다. ML 팀과 핸드오프 CSV 구조 표준화, 데이터 전환방식 등을 결정하여 데이터 처리 파이프라인의 일관성을 확보하였다.

박지은 ECG 필터 설계에 앞서 불량 데이터 판별 기준에 대한 자료 조사를 수행하였으며, band-pass filter 를 활용한 필터 설계 초기 작업을 담당하였다. 이후 ECG/PPG 파형을 직접 확인하며 Pipeline 코드 데이터 판별 과정을 분석, 수정하였다.

성인우 Pan-Tompkins 방식 기반 R-peak 을 검출 알고리즘을 구현하였다. 미분(Derivative), 제곱(Squaring), 이동창 적분(Moving Window Integration), 동적 임계값 기반 후보 검출 및 위치 재보정(Local Maximum Refinement) 과정을 포함하는 검출 알고리즘을 설계하였다. 또한 검출 결과를 CSV 로 저장하고 ECG/PPG 신호와 검출 위치를 오버레이한 그래프를 자동 생성하는 기능을 구현하였다.

이찬우 PPG 미분 후 기울기 급변 지점 직전의 극솟값을 찾는 foot 검출 기법을 조사하고, PTT, PAT, RR Interval 데이터를 CSV 파일로 자동 도출하는 코드를 구현하여 생체 신호 분석 파이프라인 구축에 기여하였다.

김시우^{TL} 머신러닝 팀장으로서 프로젝트 진행 관리, 팀원 지도, 타 팀과의 결과 공유를 담당하였다. 혈압 추정을 위한 머신러닝 프레임워크를 설계하고, XGBoost-Lasso 하이브리드 모델을 기반으로 예측 성능 향상 및 학습 효율화 방안을 제안·구현하였다. 또한 가상 데이터셋 생성, Data Augmentation(Uniform, Gaussian, Dynamic Gaussian, Mixed) 알고리즘 개발, Internal Split·Prediction·External Test 모드 구현을 수행하였다. 하이퍼파라미터 최적화(Grid Search), 반복 예측 기반 일반화 성능 평가, 모델 검증 및 테스트 자동화를 구축하였으며, 코드 단순화와 사용자 편의성 개선, Error Distribution 시각화 기능을 제안하였다.

한수빈^{IL} SVR(Support Vector Regression) 모델을 조사·구현하고, SBP 와 DBP 의 상관관계를 활용한 혈압 예측 모델 구조를 제안 및 개발하였다. 또한 하이퍼파라미터 최적화 기능을 구현하고, 데이터셋 구축 및 학습 파이프라인 설계를 수행하였다. 데이터 전처리, SBP·DBP 예측, 통합 예측, 성능 평가 및 결과 출력 과정을 포함하는 개발 구조를 설계하였으며, 코드 구조 단순화와 가독성 개선을 진행하였다. 데모 및 실제 데이터셋을 활용한 모델 검증, 개인화 모델 테스트 기능 구현, 결과 분석을 수행하였고, 프로젝트 진행 관리와 타 팀과의 협업 및 결과 공유를 담당하였다.

김수민 Random Forest(RF) 기반 혈압 예측 모델을 조사·구현하고, 하이퍼파라미터 최적화 기법을 연구하였다. 초기에는 Grid Search 기반 최적화를 설계하여 후보군 탐색 방식을 구현하였으며, 이후 Optuna 기반 자동 최적화 방식으로 개선하였다. 또한 Leave-One-Group-Out(LOCO) 교차검증을 도입하여 기존 GroupKFold 대비 향상된 예측 성능을 확보하였고, 변수 중요도 추출 및 시각화 기능을 구현하였다. SBP 와 DBP 의 생리학적 특성을 반영하기 위해 각각의 하이퍼파라미터 최적화 함수를 분리 설계하였으며, 모델 성능 분석 및 검증을 수행하였다.

오윤지 Random Forest 기반 혈압 예측 모델의 성능 향상을 위해 하이퍼파라미터 탐색 범위를 확장하고 최적화 기법을 개선하였다. 기존의 제한적인 탐색 범위(Max Depth 2~5 등)를 연속 탐색 방식(Max Depth 3~20)으로 확장하고, n_estimators, min_samples_split, min_samples_leaf 등의 탐색 범위를 확대하여 최적 파라미터 탐색 성능을 개선하였다. 또한 Optuna 기반 베이지안 최적화를 적용하여 효율적인 하이퍼파라미터 자동 튜닝 환경을 구축하였다. 데이터 전처리 단계에서는 IQR 기반 이상치 제거 기법을 적용하였으며, 소규모 데이터셋 환경에서의 데이터 손실 문제를 분석하여 IQR multiplier 를 조정함으로써 노이즈 제거와 데이터 보존 간의 균형을 최적화하였다.

김찬미 SVR(RBF Kernel) 기반 혈압 예측 모델을 조사·구현하고, RandomizedSearchCV 를 활용한 하이퍼파라미터 자동 최적화(C, epsilon, gamma)를 적용하였다. Target(y) 스케일링 기법을 도입하여 예측 성능을 개선하였으며, MAE, RMSE, R², AAMI 기준, BHS 등급 등을 포함한 성능 평가 체계를 구축하였다. 또한 UCI Cuffless BP, PPG-BP, DedSec-1 등 다양한 혈압 데이터셋을 조사·분석하고, UCI 데이터셋의 Feature 품질 한계 및 성능 저하 원인을 분석하였다. 데이터 누수(Data Leakage), 이중 스케일링, 변수 정의 오류 등 주요 문제를 발견·수정하여 코드 품질과 신뢰성을 향상시켰으며, 가상 데이터셋과 실제 데이터셋을 활용한 모델 검증을 수행하였다. 이를 통해 qwertyiop 데이터셋에서 SBP MAE 6.29 mmHg 및 BHS Grade B 수준의 성능을 확인하였다.

김민제^{TL} 유효검증 팀장으로서 프로젝트의 생리학적 타당성 검증 및 성능 평가 기준 수립을 담당하였다. 혈압 추정 이론과 임상 기준을 조사하여 평가 프로토콜을 설계하였으며, 데이터 품질 관리 및 결과 해석을 총괄하였다.

유지연^{IL}, 신지윤, 김민서, 이동민 측정 프로토콜 및 피험자 관리 가이드라인을 수립하였다. 카페인 섭취, 운동 여부, 자세 등 혈압 측정에 영향을 미치는 생리적 요인을 통제하기 위한 실험 절차를 설계하였다. 신호 품질 평가(SQI) 및 데이터

Reject 기준을 조사하고 정립하였다. ECG 및 PPG 신호의 품질 지표를 정의하고 이상 데이터 제거 기준 수립에 기여하였다. 모델 성능을 AAMI/ESH/ISO 81060-2 기준에 따라 분석하였다. MAE, RMSE, Mean Error, R^2 등을 활용하여 모델의 임상적 활용 가능성을 평가하고 결과를 해석하였다.

References

- [1] J. Allen, "Photoplethysmography and its application in clinical physiological measurement," *Physiol. Meas.*, vol. 28, no. 3, pp. R1-R39, Mar. 2007.
- [2] R. Mukkamala, J.-O. Hahn, O. T. Inan, L. K. Mestha, C. Kim, and S. Töreyn, "Toward ubiquitous blood pressure monitoring via pulse transit time: Theory and practice," *IEEE Trans. Biomed. Eng.*, vol. 62, no. 8, pp. 1879-1901, Aug. 2015.
- [3] P. A. Payne, C. N. Symeonides, and D. J. Webb, "Maximal arterial pulse transit time as an indicator of blood pressure changes," *Med. Biol. Eng. Comput.*, vol. 44, no. 6, pp. 507-512, Jun. 2006.
- [4] J. Solà, A. Proença, D. Ferrario, J. Porchet, J. Falhi, and M. Grossenbacher, "Non-invasive and non-occlusive blood pressure estimation via a chest sensor," *IEEE Trans. Biomed. Eng.*, vol. 60, no. 12, pp. 3505-3513, Dec. 2013.
- [5] M. Elgendi, "On the analysis of fingertip photoplethysmogram signals," *Curr. Cardiol. Rev.*, vol. 8, no. 1, pp. 14-25, Feb. 2012.
- [6] J. Pan and W. J. Tompkins, "A real-time QRS detection algorithm," *IEEE Trans. Biomed. Eng.*, vol. BME-32, no. 3, pp. 230-236, Mar. 1985.
- G. B. Moody and R. G. Mark, "The impact of the MIT-BIH Arrhythmia Database," *IEEE Eng. Med. Biol. Mag.*, vol. 20, no. 3, pp. 45-50, May-Jun. 2001.
- [7] H. Gesche, D. Grosskurth, G. Küchler, and A. Patzak, "Continuous blood pressure measurement by using the pulse transit time: Comparison to a cuff-based method," *Eur. J. Appl. Physiol.*, vol. 112, no. 1, pp. 309-315, Jan. 2012.
- [8] S. Choudhury, T. Banerjee, and S. K. Sanyal, "Cuffless blood pressure estimation using pulse transit time and machine learning techniques," *Biomed. Signal Process. Control*, vol. 68, Art. no. 102610, 2021.
- [9] G. Parati et al., "Recommendations for blood pressure measuring devices validation according to the AAMI/ESH/ISO Universal Standard," *J. Hypertens.*, vol. 37, no. 3, pp. 459-466, Mar. 2019.
- [10] ANSI/AAMI/ISO 81060-2:2019, Non-Invasive Sphygmomanometers—Part 2: Clinical Investigation of Intermittent Automated Measurement Type, Association for the Advancement of Medical Instrumentation (AAMI), Arlington, VA, USA, 2019.
- [11] STMicroelectronics, "STM32F4 Series Reference Manual," STMicroelectronics, Geneva, Switzerland, 2024.
- [12] Analog Devices, "AD8232 Heart Rate Monitor Front End Data Sheet," Analog Devices, Wilmington, MA, USA, 2023.
- [13] Analog Devices, "MAX30102 High-Sensitivity Pulse Oximeter and Heart-Rate Sensor Data Sheet," Analog Devices, Wilmington, MA, USA, 2023.
- [14] C. Cortes and V. Vapnik, "Support-vector networks," *Mach. Learn.*, vol. 20, no. 3, pp. 273-297, Sep. 1995.
- [15] L. Breiman, "Random forests," *Mach. Learn.*, vol. 45, no. 1, pp. 5-32, Oct. 2001.
- [16] R. Tibshirani, "Regression shrinkage and selection via the lasso," *J. Roy. Stat. Soc. B*, vol. 58, no. 1, pp. 267-288, 1996.